

# 朴素贝叶斯模型详解

李文哲

贪心学院, NLP训练营  
wenzheli@usc.edu

---

## Abstract

朴素贝叶斯模型是文本分析领域最为常用的模型之一, 也是最为经典的模型。文本主要从教学的角度来讲解朴素贝叶斯模型以及数学原理。为了让文档具备完备性, 必要的前置知识也包含在文章里。

*Keywords:* 朴素贝叶斯模型, 数学推导

---

## 1. 预备数学知识

### 1.1. 求极值问题

人工智能中最核心的数学环节是求出一个目标函数 (object function) 的最小值/最大值。求出一个函数最小是/最大值的方法很多, 在这里我们介绍一个最经典的方法之一: 直接求出极值点。这些极值点的共同特点是在这些点上的梯度为0, 如下图所示 1。这个图里面, 有8个极值点, 而且这些极值点中必然会存在最小值或者最大值 (除去函数的左右最端点)。所以在这种方式下, 我们通常先求出函数的导数, 然后设置成为0。之后从找出的极值点中选择使得结果为最小值/最大值的极值点。

例1: 求 $f(x) = x^2 - 2x - 3$ 的最小值。对于这样的一个问题, 其实我们都知道这个问题的答案是 $x = 1$ , 基本上不需要计算就能看出来。接下来我们通过求导的方式来求一下最小值。首先对 $f(x)$ 求导并把导数设置成0。

$$f'(x) = 2x - 2 = 0$$

从而得到 $x = 1$ , 求出来的是唯一的极值点, 所以最后得出来的函数的最小值是 $f(1) = 1 - 2 - 3 = -4$




Figure 1: 函数图(包含8个极值点)

例2: 求  $f(x) = x^4 - 3x^2 + 4$  的最小值.

$$f'(x) = 4x^3 - 6x = 0$$

15 即可以得到  $x_1 = 0, x_2 = \sqrt{\frac{3}{2}}, x_3 = -\sqrt{\frac{3}{2}}$ . 把这三个值分别带入到  $f(x)$  即  
 16 可以得到  $f(0) = 4, f(\sqrt{\frac{3}{2}}) = \frac{9}{4} - \frac{9}{2} + 4 = \frac{7}{4}, f(-\sqrt{\frac{3}{2}}) = \frac{7}{4}$ . 所以,  $x_2, x_3$  两  
 17 个点都可以作为函数的最小值点, 这时候函数值为  $\frac{7}{4}$ .

18 \*请注意: 并不一定所有函数的极值都可以通过设置导数为0的方式求  
 19 出。也就是说, 有些问题中当我们设定导数为0时, 未必能直接计算出满足  
 20 导数为0的点 (比如逻辑回归模型), 这时候就需要利用数值计算相关的技  
 21 术 (最典型为梯度下降法, 牛顿法..)

## 22 1.2. 拉格朗日乘法项 (Lagrangian Multiplier)

23 对于某些求极值问题, 函数通常带有一些条件。如下面的例子:

24 例3: 求  $f(x, y) = x + y$  的最大值, 但有个条件是  $x^2 + y^2 = 1$ . 。那这时候怎  
 25 么求出最大值呢?

26 拉格朗日乘法项就是用来解决这类问题。我们可以把限制条件通过简单  
 27 的转变加到目标函数中, 这时候问题就变成了

$$\text{maximize } L = x + y + \lambda(x^2 + y^2 - 1)$$

剩下的过程就跟上面的类似了。设定导数为0，即可以得到以下三个方程：

$$f'_x(x, y, \lambda) = 1 + 2\lambda x = 0 \quad (1)$$

$$f'_y(x, y, \lambda) = 1 + 2\lambda y = 0 \quad (2)$$

$$f'_\lambda(x, y, \lambda) = x^2 + y^2 - 1 = 0 \quad (3)$$

解完之后即可以得到 $\lambda_1 = \frac{\sqrt{2}}{2}, \lambda_2 = -\frac{\sqrt{2}}{2}$ 。针对于每一个 $\lambda$ 我们得到的解为 $(x = \frac{\sqrt{2}}{2}, y = \frac{\sqrt{2}}{2}), (x = -\frac{\sqrt{2}}{2}, y = -\frac{\sqrt{2}}{2})$ 。把两个解带入到原来函数里并做比较即可以确定最优解。

### 1.3. 最大似然估计 (Maximum Likelihood Estimation)

最大似然估计是机器学习领域最为常见的用来构建目标函数的方法。它的核心思想是根据观测到的结果来预测其中的未知参数。我们举一个投掷硬币的例子。

假设有一枚硬币，它是不均匀的，也就是说出现正面的反面的概率是不同的。假设我们设定这枚硬币出现正面的概率为 $p(H) = \theta$ ，这里 $H$ 指的是正面(head)，类似的还会有反面 (tail)。假设我们投掷6次之后得到了以下的结果，而且我们假定每次投掷都是相互独立的事件：

$$D = \{H, T, T, H, H, H\}$$

其中 $D$ 表示所观测到的所有样本。从这个结果其实谁都可以很容易说出 $\theta$ ，也就是出现正面的概率为4/6，其实我们在无意识中使用了最大似然估计法。接下来，我们从更严谨的角度来定义最大似然下的目标函数。

基于最大似然估计法，我们需要最大化观测到样本的概率，即 $p(D)$ 。进一步可以写成：

$$p(D) = p(HTTTHHH) = \theta * (1 - \theta) * (1 - \theta) * \theta * \theta * \theta$$

我们的目标是最大化概率值 $L = \theta * (1 - \theta) * (1 - \theta) * \theta * \theta * \theta$ 。那这部分的优化即可以采用上面所提到的方法。

$$L'(\theta) = 4\theta^3(1 - \theta)^2 - \theta^4 * 2 * (1 - \theta) = 0$$

把这个式子整理完之后即可以得到 $\theta = 2/3$ ，结果跟一开始我们算出来的一致。

## 48 2. 朴素贝叶斯(Naive Bayes)

49 假设给定了一批训练数据  $D = \{(x^1, y^1), \dots, (x^N, y^N)\}$ , 其中  $x^i$  指的是  
 50 第  $i$  个样本 (文章), 而且这个样本 (文章) 包含了  $m_i$  个单词, 所以  
 51 可以把  $x^i$  表示成  $x^i = (x_1^i, x_2^i, \dots, x_{m_i}^i)$ . 假设  $x^i$  的全文内容为 "今天很高兴  
 52 来参加自然语言处理训练营", 那这时候  $x_1^i =$  "今天",  $x_2^i =$  "很",  $x_3^i =$  "高  
 53 兴",  $x_4^i =$  "来",  $x_5^i =$  "参加",  $x_6^i =$  "自然语言处理",  $x_7^i =$  "训练营". 所以这里  $m_i =$   
 54 7. 另外,  $y^i$  代表的是  $x^i$  的标签。比如在垃圾邮件应用上, 它代表 "垃圾邮  
 55 件", "正常邮件"。我们利用  $K$  来代表分类的个数。比如在垃圾邮件应用  
 56 上  $K = 2$ 。但在这里, 我们考虑普遍的情况, 很有可能  $K > 2$ , 也称之为是  
 57 多分类问题。最后, 我们再定义  $V$  为词典库的大小。

朴素贝叶斯是生成模型, 它的目标是要最大化概率  $p(D)$ , 也就是  $p(x, y)$ 。  
 我们把前几步的推导先写一下:

$$p(D) = \prod_{i=1}^N p(x^i, y^i) = \prod_{i=1}^N p(x^i | y^i) p(y^i) \quad (4)$$

$$= \prod_{i=1}^N p(x_1^i, x_2^i, \dots, x_{m_i}^i | y^i) p(y^i) \quad (5)$$

$$= \prod_{i=1}^N \prod_{j=1}^{m_i} p(x_j^i | y^i) p(y^i) \quad (6)$$

58 这里简单说明一下: 式子(4)是利用的贝叶斯公式, 式子(4)到(5)的变化是  
 59 利用了一个事实: 样本  $x^i$  由很多个单词来构成, 这里每一个  $x_j^i$  看作是一个  
 60 单词。式子(5)到(6)是利用了朴素贝叶斯的假设, 也就是每个词都是相互  
 61 独立的。比如给定一个句子 "我们今天运动", 在给定一个标签  $y$  的情况下,  
 62 概率可以写成  $p(\text{"我们今天运动"} | y) = p(\text{我们} | y) * p(\text{今天} | y) * p(\text{运动} | y)$ 。

我们看到式子里面都是乘法项, 而且多个乘法项很容易引起数据的  
 overflow或则underflow(在这里是underflow)。所以我们一般不直接最大  
 化  $p(D)$ , 而是最大化  $\log p(D)$ , 其实这两个是等同的。因为  $\log$  函数是严格递

增的函数。加上log，我们对上面式子做一些变化：

$$\log p(D) = \log\left(\prod_{i=1}^N \prod_{j=1}^{m_i} p(x_j^i | y^i) p(y^i)\right) \quad (7)$$

$$= \log\left(\prod_{i=1}^N \prod_{j=1}^V p(w_j | y^i)^{n_{ij}} p(y^i)\right) \quad (8)$$

$$= \sum_{i=1}^N \sum_{j=1}^V n_{ij} \log p(w_j | y^i) + \sum_{i=1}^N \log p(y^i) \quad (9)$$

$$= \sum_{k=1}^K \sum_{i: y^i=k} \sum_{j=1}^V n_{ij} \log p(w_j | y^i = k) + \sum_{k=1}^K \sum_{i: y^i=k} \log p(y^i = k) \quad (10)$$

$$= \sum_{k=1}^K \sum_{i: y^i=k} \sum_{j=1}^V n_{ij} \log \Theta_{kj} + \sum_{k=1}^K \sum_{i: y^i=k} \log \pi_k \quad (11)$$

$$= \sum_{k=1}^K \sum_{i: y^i=k} \sum_{j=1}^V n_{ij} \log \Theta_{kj} + \sum_{k=1}^K n_k \log \pi_k \quad (12)$$

从式子(7)到式子(8)的转化利用了一些技巧。举例子，假设一个文章的内容为“我们 天 天 运动”，按照之前的逻辑这句话的概率为 $p(\text{“我们天天运动”}|y) = p(\text{我们}|y)p(\text{天}|y)p(\text{天}|y)p(\text{运动}|y)$ 。但另一方面，我们也可以利用词典库的所有词来代表这个概率。 $p(\text{我们天天运动}|y) = p(\text{“啊”}|y)^0 p(\text{哎}|y)^0 \dots p(\text{天}|y)^2 \dots p(\text{我们}|y)^1 \dots p(\text{运动}|y)^1 \dots$ 。这两者是等同的，只不过我们从词典库的维度把所有的单词都考虑了进来，并数一下每一个单词在文档 $i$ 里出现了多少次，如果没有出现，相当于0次。所以从这个角度我们可以把 $\prod_{j=1}^{m_i} p(x_j^i | y^i)$ 写成 $\prod_{j=1}^V p(w_j | y^i)^{n_{ij}}$ ，其中 $n_{ij}$ 代表单词 $j$ 出现在文档 $i$ 的次数。这里 $w_j$ 代表词典库里的第 $j$ 个单词。

从式子(8)到(9)是利用了log的性质。比如 $\log x^y = y \log x$ ,  $\log \prod_{i=1}^N p(x^i) = \sum_{i=1}^N \log p(x^i)$ 。式子(9)到式子(10)是把文档按照类别做了一个分类。也就是，一开始的时候我们是从文档1到N的顺序来循环，但现在我们先取出类别为1的文档，然后再取出类别为2的文档，以此类推。所以前面的 $\sum_{i=1}^N$ 被拆分成两个sum，即 $\sum_{k=1}^K \sum_{i: y^i=k}$ 。这里 $i : y^i = k$ 代表属于类别 $k$ 的所有文档。式子(10)到式子(11)是引入了两组变量。也就是我们直接设置 $p(w_j | y^i = k)$ 为 $\Theta_{kj}$ ，意思就是当文章分类为 $k$ 的时候出现单词 $w_j$ 的概率 ( $\Theta_{kj}$ )。另外，我们设定 $p(y^i = k)$ 为 $\pi_k$ ，也就是文档属于第 $k$ 类的概率，这个也是朴素贝叶斯模型的先验(prior)。比如在垃圾识别应用中，

81 假设总共有100个垃圾邮件和1000个正常邮件，这时候一个邮件为垃圾邮  
 82 件的概率为1/11，正常邮件的概率为10/11，这就是贝叶斯模型的先验，  
 83 而且所有之和等于1。式子(11)到式子(12)是引入一个新的变量叫做 $n_k$ ，  
 84 也就是属类别 $k$ 的文件个数（训练数据总统计即可，是已知的）。也就  
 85 是 $\sum_{i:y^i=k} \pi_k = n_k \pi_k$ 。

另外，有两个约束条件需要满足，分别是：

$$\sum_{u=1}^K \pi_u = 1 \quad (13)$$

$$\sum_{v=1}^V \Theta_{kv} = 1, \text{ for } k = 1, 2, \dots, K \quad (14)$$

86 条件(13)表示的是所有类别的概率加在一起等于1。比如 $p(\text{垃圾}) + p(\text{正常}) =$   
 87 1。条件(14)表示的是对于任意一个分类 $k$ ，出现所有词典里的单词的总概率  
 88 合为1。

89 所以，这个问题是有约束条件的优化问题。把约束条件和目标函数写在  
 90 一起即可以得到：

$$\text{Maximize } L = \sum_{k=1}^K \sum_{i:y^i=k} \sum_{j=1}^V n_{ij} \log \Theta_{kj} + \sum_{k=1}^K n_k \log \pi_k$$

$$s.t. \sum_{u=1}^K \pi_u = 1 \quad (15)$$

$$\sum_{v=1}^V \Theta_{kv} = 1, \text{ for } k = 1, 2, \dots, K \quad (16)$$

91 利用拉格朗日乘法项，我们可以把目标函数写成：

$$\text{Maximize } L = \sum_{k=1}^K \sum_{i:y^i=k} \sum_{j=1}^V n_{ij} \log \Theta_{kj} + \sum_{k=1}^K n_k \log \pi_k + \lambda \left( \sum_{u=1}^K \pi_u - 1 \right) + \sum_{k=1}^K \lambda_k \left( \sum_{v=1}^V \Theta_{kv} - 1 \right) \quad (17)$$

92 2.0.1. 找出最优解 $\pi_k$

我们需要设置导数为0，进而找出最优解。现在求解的是 $\pi_k$ ，所以只要

跟 $\pi_k$ 无关的项我们都可以不用考虑，因为它们导数为0。  $L$ 对 $\pi_k$ 的导数为：

$$\frac{\partial L}{\partial \pi_k} = \frac{\partial(n_k \log \pi_k + \lambda \pi_k)}{\partial \pi_k} \quad (18)$$

$$= \frac{n_k}{\pi_k} + \lambda = 0 \quad (19)$$

93 解为 $\pi_k = -\frac{1}{\lambda}n_k$ 。这里有个参数 $\lambda$ ，但同时我们有一个约束条件是 $\sum_{u=1}^K \pi_u =$   
94 1，我们把刚才的解带入到这里，可以得到：

$$\sum_{u=1}^K -\frac{1}{\lambda}n_u = 1 \quad (20)$$

95 则 $\lambda$ 的值为 $\lambda = -\sum_{u=1}^K n_u$ 。把 $\lambda$ 再次带入到 $\pi_k$ 里面，我们可以得到：

$$\pi_k = \frac{n_k}{\sum_{u=1}^K n_u} \quad (21)$$

96 这里面 $n_k$ 为 $k$ 类文档出现的个数，分母为所有文档的个数。

97 2.1. 找出最优解 $\Theta_{kj}$

类似的，我们需要求 $L$ 对 $\Theta_{kj}$ 的导数为：

$$\frac{\partial L}{\partial \Theta_{kj}} = \frac{\partial(\sum_{i:y^i=k} n_{ij} \log \Theta_{kj}) + \lambda_k(\sum_{v=1}^V \Theta_{kv} - 1)}{\partial \Theta_{kj}} \quad (22)$$

$$= \sum_{i:y^i=k} \frac{n_{ij}}{\Theta_{kj}} + \lambda_k = 0 \quad (23)$$

98 解为 $\Theta_{kj} = -\frac{1}{\lambda_k} \sum_{i:y^i=k} n_{ij}$ 。这里有个参数是 $\lambda_k$ ，但同时我们有个约束条件  
99 是 $\sum_{v=1}^V \Theta_{kv} = 1$ ，把刚才的解带入到这里，可以得到：

$$\lambda_k = -\frac{1}{\sum_{v=1}^V \sum_{i:y^i=k} n_{iv}} \quad (24)$$

100 把 $\lambda_k$ 带入到上面的解即可以得到：

$$\Theta_{kj} = \frac{\sum_{i:y^i=k} n_{ij}}{\sum_{v=1}^V \sum_{i:y^i=k} n_{iv}} \quad (25)$$

101 这个式子中分子代表的是在所有类别为 $k$ 的文档里出现了多少次 $w_j$ ，也就是  
102 词典库里的 $j$ 个单词。分母代表的是在类别为 $k$ 的所有文档里包含了总共多  
103 少个单词。

104 到此为止，模型的参数已经得到。如有发现错误，请联系作者。感谢阅  
105 读。